



UNIVERSITAS DIPONEGORO



Statistical Machine Learning

Implementasi Transfer Learning Berbasis
Arsitektur Transformer (Flan-T5) untuk
Klasifikasi *Toxic Comments*

Presented by: KELOMPOK 4

Anggota Kelompok

- Yudit Ginsa Kurnia Putri 24050123120002
- Berliana Tessa Shavira 24050123120009
- Agatha Kristania Prineysa 24050123120034
- Muhammad Kholid Bisyri 24050123130065
- Wong, Ryan Sebastian 24050123130107



PENDAHULUAN



LATAR BELAKANG

Penggunaan media sosial yang masif memunculkan banyak komentar *toxic* seperti hinaan, ancaman, dan pelecehan. Hal ini berdampak pada kualitas komunikasi digital dan kondisi psikologis pengguna. Pendekatan konvensional seperti Logistic Regression dan SVM masih memiliki keterbatasan dalam memahami konteks bahasa. Model tersebut juga kesulitan menangani bahasa tidak formal, singkatan, dan emoji sehingga akurasi deteksi menjadi kurang optimal.



SOLUSI PEMODELAN



Penelitian ini menggunakan arsitektur Transformer yang lebih mampu memahami konteks bahasa. Pendekatan Transfer Learning diterapkan melalui model Flan-T5 untuk melakukan klasifikasi komentar beracun secara otomatis. Proses ini juga mencakup konversi emoji menjadi teks agar informasi emosi tetap dapat dipahami oleh model.

FOKUS PENELITIAN

Analisis Data Eksploratif

Mengidentifikasi karakteristik sebaran data teks, kosakata dominan, dan distribusi panjang kalimat.

Implementasi Model

Menerapkan arsitektur Flan-T5 berbasis Transfer Learning untuk mengklasifikasikan teks menggunakan pendekatan instruksi dan terjemahan emoji.

Evaluasi Kinerja

Mengukur tingkat keandalan dan akurasi model pembelajaran mesin tersebut menggunakan metrik statistik F1-Macro dan Confusion Matrix.

Batasan Masalah

Fokus Kemampuan Model

Fungsi model Flan-T5 (text-to-text) dibatasi secara khusus hanya untuk tugas klasifikasi.

Pembatasan Output

Menggunakan prompt engineering agar model hanya menghasilkan 3 kategori label target: Insult, Threat, atau Sexual Harassment.

Cakupan Dataset

Mengukur tingkat keandalan dan akurasi model pembelajaran mesin tersebut menggunakan metrik statistik F1-Macro dan Confusion Matrix.

Metrik Evaluasi

Pengukuran performa klasifikasi dibatasi menggunakan statistik evaluasi F1-Macro dan Confusion Matrix.



TINJAUAN PUSTAKA



PREPROCESSING DAN EDA

Tahap awal dilakukan untuk memahami karakteristik data dan membersihkan teks. Emoji dikonversi menjadi teks menggunakan demojize agar informasi emosi tetap dapat diproses oleh model.

EDA

Diagram Batang dan Word Cloud

Digunakan untuk mengevaluasi keseimbangan proporsi kelas dan memetakan kosakata yang dominan.

Histogram dan Boxplot

Digunakan untuk mengidentifikasi sebaran dan pemusatan panjang kalimat sebagai acuan batas pemotongan teks.

TRANSFORMER DAN FLAN-T5

Flan-T5

Model spesifik buatan Google yang dapat digunakan untuk mendeteksi komentar *toxic*.

Pendekatan Text-to-Text

Algoritma ini tidak menebak menggunakan probabilitas angka, melainkan merespons tugas klasifikasi dengan cara menghasilkan teks tulisan secara langsung.

Penelitian ini menggunakan arsitektur Transformer yang mampu memahami konteks melalui mekanisme *self-attention*. Pendekatan Transfer Learning digunakan agar model dapat memanfaatkan pengetahuan dari pelatihan sebelumnya.

KOMPONEN UTAMA

Komponen Utama

- Encoder: berfungsi untuk memahami teks masukan dan menangkap konteks dari kalimat
- Decoder: berfungsi untuk menghasilkan teks keluaran berdasarkan hasil pemahaman tersebut

Struktur pada Flan-T5

Model Flan-T5 mempertahankan arsitektur encoder-decoder secara utuh sebagaimana desain Transformer asli

Keunggulan Sistem

- Mampu memahami isi teks (*text understanding*)
- Mampu menghasilkan teks (*text generation*)
- Kedua kemampuan tersebut berjalan dalam satu model yang sama

PROMPT ENGINEERING DAN FINE-TUNING

Sebelum diproses, teks tulisan manusia dikonversi menjadi representasi numerik melalui proses tokenisasi. Kalimat juga diberikan lapisan bantalan (padding) agar ukuran input menjadi seragam di dalam matriks.

- Prompt Engineering → Kalimat data mentah digabungkan dengan awalan teks perintah agar model memahami konteks tugas secara eksplisit.
- Fine-Tuning → Sistem dilatih ulang menggunakan data spesifik dengan mengatur parameter putaran pembelajaran (*epoch*) dan kecepatan adaptasi (*learning rate*) untuk meningkatkan ketajaman prediksi.

METRIK EVALUASI PERFORMA MODEL

F1-Macro

Mengukur rata-rata secara independen pada setiap kategori teks. Pendekatan ini mengukur performa tiap kelas secara seimbang

Confusion Matrix

Memetakan hasil tebakan dan jawaban asli ke dalam tabel silang. Analisis visual ini digunakan untuk menganalisis kesalahan klasifikasi antar kategori



METODOLOGI



Data dan Sumber Data

Data merupakan data sekunder yang diperoleh dari website Kaggle.com. Data yang digunakan dalam penelitian ini adalah dataset Toxic Comments berjumlah 5910 komentar. Dataset ini berisi teks komentar dari berbagai sumber digital yang telah dilabeli secara manual ke dalam tiga kategori klasifikasi yaitu Insult (Makian/Hinaan), Threat (Ancaman), dan Sexual Harassment (Pelecehan Seksual).

id	Toxic Comment	Classification
1409	this is why nobody respects women in business	Insult
2881	Watch what happens if you keep this up 🦴🔪🔪	Threat
4450	that thirst trap got me acting unwise respectfully	Sexual Harassment
3535	I'd pay to see you t@k3 th0\$3 clothes off	Sexual Harassment
7370	hey stupid, you got <u>time</u> ?.....	Insult
4192	she's selling <u>hopium</u> to desperate fans	Sexual Harassment
1251	I'll ensure you never get that promotion	Threat
...	...	...

Langkah Analisis Data

1. Persiapan Lingkungan dan Impor Pustaka

2. Pembersihan dan Preprocessing Data:

- Pemeriksaan data duplikat: Kolom dengan id yang sama di-drop.
- Penanganan nilai kosong: Kolom teks yang bernilai NaN diisi dengan string ("").
- Demojize: Model LLM sering kali mengabaikan simbol unicode, maka dilakukan proses konversi emoji menjadi teks deskriptif menggunakan pustaka emoji.
- Prompt Engineering: Setiap komentar digabungkan dengan prefix instruksi: "Classify this comment as insult, threat, or sexual harassment: ".
- Normalisasi Target: Label klasifikasi diubah menjadi huruf kecil (lowercase) dan dibersihkan dari spasi.

3. Exploratory Data Analysis (EDA)

- Visualisasi Bar plot untuk melihat distribusi proporsi antarkelas.
- Visualisasi Histogram plot dan Boxplot untuk menganalisis statistik deskriptif dari jumlah kata per komentar di tiap kategori.
- Pembuatan Word Cloud per kategori untuk menganalisis frekuensi kemunculan slang atau kosakata spesifik.

Langkah Analisis Data

4. Pemodelan dan Fine-Tuning:

Data dibagi dengan rasio 85% data latih (training) dan 15% data validasi. Parameter stratify digunakan agar rasio kelas pada data validasi merepresentasikan rasio pada data populasi. Selanjutnya, teks masukan dan target diubah menjadi deret angka menggunakan Tokenizer bawaan Flan-T5. Teks dibatasi dengan parameter `max_length=128` untuk efisiensi komputasi berdasarkan hasil EDA. Padding dilakukan agar panjang matriks seragam, dan token padding pada label target diubah menjadi nilai -100 agar fungsi loss mengabaikan perhitungan pada token kosong tersebut.

5. Evaluasi Model

Model yang telah dilatih akan memprediksi data validasi. Hasil teks prediksi dibandingkan dengan label asli untuk membentuk Confusion Matrix dan menghitung akurasi secara keseluruhan.



HASIL DAN PEMBAHASAN



Tautan Dataset

https://drive.google.com/drive/folders/1JRiQ-WyyCmlgAy6fyxukdyvqZCE8PO6m?usp=drive_link


Tautan Notebook

<https://colab.research.google.com/drive/1NhdmckoPUf2CHdmR0RzG58ONXJN0LWSA?usp=sharing>

Hasil Preprocessing Data

t5 input	t5 target	<u>word count</u>
Classify this comment as insult, threat, or sexual harassment: this is why nobody respects women in business	insult	8
Classify this comment as insult, threat, or sexual harassment: Watch what happens if you keep this <u>up</u> <u>:skull::water pistol::water pistol:</u>	threat	9
Classify this comment as insult, threat, or sexual harassment: that thirst trap got me acting unwise respectfully	sexual harassment	8
Classify this comment as insult, threat, or sexual harassment: I'd pay to see you t@k3 th0\$3 clothes off	sexual harassment	9
Classify this comment as insult, threat, or sexual harassment: hey stupid, you got <u>time?</u>	insult	5
Classify this comment as insult, threat, or sexual harassment: she's selling <u>hopium</u> to desperate fans	sexual harassment	6
...	...	...



EDA: Distribusi Kata



Kategori Insult menduduki proporsi tertinggi dengan jumlah 2.111 observasi (35,6%). Kategori Threat menyusul di urutan kedua dengan 1.982 observasi (33,5%), sementara kategori Sexual Harassment menjadi kelas minoritas dengan jumlah 1.826 observasi (30,8%).


Adanya selisih proporsi (di mana Sexual Harassment adalah kelas minoritas) menjadi justifikasi empiris dihindarinya metrik akurasi biasa dan digunakannya F1-Macro sebagai metrik evaluasi penentu (`metric_for_best_model="f1_macro"`).

EDA: Analisis Panjang Kata



Mayoritas komentar dalam dataset ini merupakan teks pendek. Puncak frekuensi tertinggi berada pada kisaran 4 hingga 9 kata per komentar, dengan panjang maksimal data di bawah 20 kata.

Karakteristik data ini memberikan justifikasi terhadap penentuan parameter model. Batas pemotongan teks (`max_length`) pada tokenizer telah mencakup 100% observasi data. Hal ini menunjukkan bahwa model Flan-T5 memproses seluruh teks tanpa pemotongan konteks informasi, sekaligus mengoptimalkan alokasi memori komputasi.



Poin krusial dalam visualisasi ini adalah keberhasilan tahap pra-pemrosesan menggunakan metode Demojize. Munculnya kata kunci seperti "pile_of_poo", "skull", "enraged_face", dan "eggplant" membuktikan bahwa simbol emoji telah berhasil dikonversi menjadi representasi teks. Konversi ini memberikan dimensi informasi tambahan bagi model Flan-T5 untuk memahami konteks emosi dan intensitas pesan yang sering kali tidak tersampaikan hanya melalui kata-kata tertulis

Model

- Model Dasar: Menggunakan arsitektur Transformer (Encoder-Decoder) yang dirancang oleh Google untuk memahami hubungan antar kata secara menyeluruh.
- Pendekatan Text-to-Text: Model ini tidak mengeluarkan angka probabilitas biasa, melainkan memproses tugas klasifikasi seperti percakapan; menerima instruksi teks dan menghasilkan jawaban label langsung dalam bentuk teks.
- Mekanisme Self-Attention: Fitur utama yang memungkinkan model memberikan "perhatian" atau bobot lebih pada kata-kata yang paling penting dalam satu kalimat.
- Keunggulan Kontekstual: Sangat efektif untuk menangkap niat (intent) pada teks pendek di bawah 20 kata, termasuk memahami makna emosi dari emoji yang telah dikonversi menjadi teks

Contoh Perbandingan Kalimat

Tipe Komentar	Contoh Kalimat (English)	Analisis Frekuensi Tradisional (TF-IDF)	Analisis Flan-T5 (Attention/Contextual)
General Insult (Penghinaan Umum)	"Hey stupid, you got time?....."	Efektif. Kata "stupid" memiliki bobot negatif yang tinggi, sehingga model mudah melabelinya sebagai Insult.	Efektif. Model memahami bahwa subjek ditujukan langsung pada kata sifat negatif "stupid".
Veiled Threat (Ancaman Terselubung)	"I'll ensure you never get that promotion."	Lemah. Kata "ensure", "get", dan "promotion" adalah kata-kata profesional yang sering muncul di teks normal. Tanpa kata kasar, model frekuensi cenderung menganggapnya	Efektif. Mekanisme attention menangkap hubungan antara "I'll ensure" + "never get" + "promotion". Model memahami adanya niat intimidasi terhadap karir

Proses Train


- *Training* pada model pre-trained Flan-T5.
- 85% Pelatihan (Training) dan 15% Validasi (Validation).
- Algoritma AdamW
- Hyperparameter Konfigurasi:
 - Learning Rate ($5e-5$): Ditetapkan pada angka rendah untuk memungkinkan adaptasi bobot secara halus tanpa merusak pengetahuan dasar model (catastrophic forgetting).
 - Epoch (5): Berdasarkan observasi pada kurva loss, model mencapai titik konvergensi pada iterasi kelima, di mana performa pada data validasi mencapai titik optimal sebelum risiko overfitting meningkat.
 - Max Length (128 Tokens): Penentuan panjang token ini disesuaikan dengan karakteristik data teks pendek (<20 kata) untuk menjaga efisiensi memori tanpa memangkas informasi penting.

Analisis Metrik Evaluasi

<u>Kelas</u>	Precision	Recall	F1-Score
Insult	0,9149	0,9233	0,9191
Threat	0,9323	0,8864	0,9087
Sexual Harassment	0,9088	0,9394	0,9238
Accuracy			0,9177
Macro Average	0,9187	0,9164	0,9172
Weighted Average	0,9180	0,9177	0,9176

Model Flan-T5 berhasil mencapai performa yang sangat solid dengan tingkat akurasi keseluruhan sebesar 91,77%. Kategori Sexual Harassment menjadi kelas yang paling efektif dideteksi oleh model dengan nilai recall tertinggi mencapai 0,9394. Sementara itu, kategori Threat menunjukkan tingkat kepercayaan prediksi paling akurat dengan nilai precision sebesar 0,9323. Tingginya nilai F1-Macro (0,9172) membuktikan bahwa model mampu memberikan hasil klasifikasi yang seimbang dan konsisten pada seluruh jenis komentar toksik, meskipun terdapat perbedaan jumlah data antar kategori.

Analisis Matrix Confusion



Visualisasi Confusion Matrix menunjukkan dominasi yang sangat kuat pada diagonal utama, yang membuktikan ketepatan model dalam mengklasifikasikan label secara akurat. Model menunjukkan performa paling solid pada kategori Insult dengan 301 prediksi benar, diikuti oleh Sexual Harassment dengan 279 prediksi benar, dan Threat sebanyak 234 prediksi benar. Rendahnya angka pada area luar diagonal utama menunjukkan bahwa model berhasil membedakan niat toksik meskipun terdapat kemiripan kosakata pada teks pendek. Kesalahan klasifikasi yang muncul merupakan hasil dari ambiguitas semantik alami pada bahasa internet, di mana satu komentar sering kali memiliki intensi ganda (multi-intent).

Analisis Kesalahan Prediksi

No	<u>Komentar Toksik</u>	Label Asli	<u>Prediksi Model</u>
1	" <u>my</u> DMs are wet for <u>you</u> :peach::eyes:"	Insult	Sexual Harassment
2	" <u>one</u> more step and u r dead"	Insult	Threat
3	"they'll never find <u>ur</u> body"	Insult	Threat

- Model Lebih Akurat Secara Kontekstual: Pada banyak kasus, prediksi model justru lebih tepat dibandingkan label asli dataset.
- Efek Demojize yang Kuat: Penggunaan emoji seperti :peach: berhasil dideteksi sebagai pelecehan seksual, bukan sekadar hinaan biasa.
- Sensitivitas Tinggi pada Ancaman: Kalimat intimidasi fisik seperti "u r dead" atau "never find ur body" ditangkap dengan sangat baik sebagai Threat oleh model.
- Koreksi Mandiri terhadap Label: Perbedaan prediksi ini menunjukkan model mampu melakukan generalisasi yang lebih baik daripada proses pelabelan manual di dataset awal.



PENUTUP

KESIMPULAN

- **Karakteristik & Pemrosesan Data**

Mayoritas data berupa kalimat pendek dengan variasi kosakata antar kelas. Penggunaan demojize efektif mempertahankan informasi emosi dengan mengonversi emoji menjadi representasi teks.

- **Implementasi Model**

Pendekatan Transfer Learning menggunakan Flan-T5 yang dipadukan dengan prompt engineering mampu mengarahkan model dalam memahami instruksi klasifikasi teks secara kontekstual.

- **Evaluasi Kinerja**

Model mencapai akurasi $>90\%$ dengan nilai F1-Macro yang menunjukkan performa cukup seimbang pada kelas minoritas. Confusion Matrix mengidentifikasi kesalahan klasifikasi, terutama antara kelas pelecehan seksual dan hinaan, akibat kemiripan kosakata.

**Thank
You**

